Universitat de Girona — Màster en Ciència de Dades
Advanced Machine Learning Techniques

Exercici de Sèries Temporals Financeres

Predicció del preu de tancament de Microsoft (MSFT)

Joan Massallé

joan.massalle@additioapp.com

Ticker assignat: **MSFT** — posició 1978883 mod 10 = 3

Abril 2026

0 Índex

1 Introducció **2**

2 Dades **3**

2.1 Descripció del dataset 3

2.2 Anàlisi exploratòria 3

3 Metodologia **4**

3.1 Partició temporal 4

3.2 Validació creuada temporal 4

3.3 Mètriques d'avaluació 4

3.4 Construcció dels intervals de confiança 5

4 Models **5**

4.1 Benchmarks 5

4.2 Models estadístics 6

4.3 Machine learning 6

4.4 Deep learning 6

4.5 Models descartats 7

5 Resultats **7**

5.1 Ranking final 7

6 Discussió **7**

6.1 GRU — Model guanyador 7

6.2 LSTM — Per què falla on GRU triomfa 8

6.3 Random Forest i XGBoost — Competitius però inestables 8

6.4 Models estadístics — Limitació estructural 9

6.5 Calibració dels intervals al test set 9

7 Conclusions **10**

7.1 Millores proposades 10

1 Introducció

L'objectiu d'aquest exercici és construir el millor model de predicció possible per a una sèrie temporal de cotitzacions borsàries, justificant totes les decisions preses durant el procés d'anàlisi, preprocessament, modelatge i avaluació.

El ticker assignat és **MSFT** (Microsoft Corporation), corresponent a la posició $1978883 \bmod 10 = 3$ de la llista de deu grans empreses tecnològiques proposada per l'assignatura. S'avaluen **9 models** competitius en precisió i calibració de la incertesa.

El codi font complet del projecte es troba disponible a: `https://github.com/Sebastiano0248/TimeSeriesExercice`

1.0 Elecció de l'horitzó de predicció

L'enunciat no fixa cap horitzó concret. S'ha escollit $h =$ **22 dies borsaris** (1 mes natural) per les raons següents:

1. **Horitzó 1 és massa fàcil per revelar diferències entre models.** A un pas vista, el Naïve ($\hat{y}_{t+1} = y_t$) és pràcticament imbatible per a qualsevol sèrie de preus: la variació d'un dia per l'altre és tan petita que tots els models convergeixen al mateix error. No hi hauria res a comparar.

2. **22 passos força els models a fer prediccions autònomes sense retroalimentació real.** La crida és `model.predict(h=22)`: el model rep l'últim preu conegut i ha de retornar els 22 valors futurs d'un sol cop, sense veure cap valor real entremig. Per als models autogressius (GRU, LSTM), això implica *iterative forecasting* — la predicció del pas $t + 1$ s'usa com a input per al pas $t + 2$, i l'error s'acumula durant els 22 passos. Aquesta condició discrimina clarament els models que generalitzen dels que s'ajusten excessivament a l'últim valor vist.

3. **Un mes borsari és una unitat pràcticament rellevant.** En finances, l'horitzó mensual és habitual en planificació de cartera i gestió de risc. La sèrie té prou temps per divergir del punt de partida i fer visibles les diferències de qualitat entre models.

La hipòtesi del mercat eficient suggereix que els preus actuals incorporen tota la informació disponible, cosa que fa que les prediccions a curt termini siguin properes a un camí aleatori (*random walk*). Superar el model Naïve — que prediu simplement que el preu de demà serà igual al d'avui — és, per tant, el primer repte a abordar; a 22 passos vista, aquest repte és substancialment més exigent que a un pas.

2 Dades

2.1 Descripció del dataset

Les dades s'han obtingut via la llibreria `yfinance` de Python, que permet descarregar l'historial complet de cotitzacions de Yahoo Finance. La sèrie cobreix **10 anys** de dades diàries de mercat: ticker MSFT (Microsoft), 2.515 observacions des del 18 d'abril de 2016 fins al 17 d'abril de 2026, a freqüència diària (dies de mercat). Cada fila correspon a una sessió borsària. La borsa de Nova York tanca caps de setmana i festius, de manera que les 2.515 observacions representen 3.651 dies naturals amb 1.136 dies sense sessió.

S'ha escollit *Close* com a variable objectiu perquè és el preu de referència estàndard per a sèries temporals financeres diàries: representa el valor consolidat al final de cada sessió i és l'únic dels quatre preus del dia (*Open*, *High*, *Low*, *Close*) que és unívoc i comparable entre dies. No s'aplica cap transformació prèvia — es modela el preu de tancament directament en termes absoluts.

2.2 Anàlisi exploratòria

Al llarg dels deu anys analitzats, el preu de l'acció de Microsoft ha passat de 42$ (abril de 2016) a un màxim de 539$ (2025), és a dir, s'ha multiplicat per tretze. Aquesta pujada sostinguda fa que el preu d'un dia qualsevol depengui molt del moment en què ens trobem, i és el principal repte per als models de predicció: el que era "normal"el 2017 no ho és el 2024.

En el dia a dia, el preu es mou de mitjana un 0.10% cap amunt, amb una variació típica de l'1.70%. Els dies extrems queden clarament marcats per la pandèmia de la COVID-19: el 13 de març de 2020 es va registrar la millor sessió del període (+14.22%) i tres dies després, el 16 de març, la pitjor (−14.74%). Durant els deu anys, Microsoft ha repartit dividend quaranta vegades (trimestralment) i no ha fet cap desdoblament d'accions.

Per a aquest exercici només s'utilitza el preu de tancament diari; la resta de columnes del dataset (preu d'obertura, màxim, mínim i volum de negociació) no entren als models.

3 Metodologia

3.1 Partició temporal

Per evitar qualsevol forma de *data leakage*, les 2.515 observacions es divideixen estrictament en ordre cronològic. El 90% s'usa per a entrenament i validació creuada, i el 10% restant es reserva com a test set, mai vist durant el disseny dels models.

Conjunt	Període	Obs.
CV data (90%)	2016-04-18 → 2023-11-14	2.263
Test set (10%)	2023-11-15 → 2026-04-17	252

Taula 1: Partició temporal del dataset.

El test set cobreix un període especialment interessant: la recuperació del mercat post-2022 fins als màxims històrics de MSFT. Això fa que el salt de distribució entre CV i test sigui significatiu i que la majoria de models prediguin pitjor del que la validació creuada suggeria.

3.2 Validació creuada temporal

S'utilitza **walk-forward cross-validation amb finestra expansiva** (10 folds). En cada fold k, el model s'entrena sobre totes les dades fins al punt k i es valida sobre el bloc immediatament posterior, mai mirant endavant:

$$\text{Fold } k: \quad \underbrace{y_1, \ldots, y_{n_k}}_{\text{train}} \mid \underbrace{y_{n_k+1}, \ldots, y_{n_k+h}}_{\text{val (h=22)}}$$

Això produeix **10 estimacions independents** del MAE i de la cobertura dels intervals, molt més robustes que un únic tall train/val. Les mètriques de CV es combinen com a $\overline{\text{MAE}} \pm \sigma$.

S'ha optat per la finestra expansiva en lloc de la lliscant perquè el preu d'una acció acumula informació: les decisions dels inversors avui es prenen tenint en compte anys d'historial de l'empresa, no només els últims mesos. Descartar l'historial antic, com fa la finestra lliscant, implicaria ignorar cicles de creixement o caigudes anteriors que el model podria aprofitar.

3.3 Mètriques d'avaluació

- **MASE** — Error absolut escalat per la dificultat de la sèrie. MASE < 1 significa superar el Naïve.
- **MAE ($)** — Error absolut mitjà en dòlars de preu.

- **RMSE ($)** — Error quadràtic mitjà; penalitza errors grans.
- **CV MAE $\pm\sigma$** — Estimació robusta del rendiment (10 folds).
- **Cobertura 80/95%** — Proporció de valors reals dins l'interval de confiança. Nominal: 0.80 i 0.95.

3.4 Construcció dels intervals de confiança

Els intervals de confiança es construeixen per **calibració conformal**: es calculen els quantils empírics 0.80 i 0.95 dels errors absoluts obtinguts als 10 folds de CV, i s'apliquen simetricament sobre les prediccions del test set:

$$\hat{y}_{t+h} \pm q_\alpha^{\mathrm{CV}}, \quad \alpha \in \{0.80,\, 0.95\}$$

Per construcció, la cobertura als folds de CV és exactament la nominal. La divergència apareix al test set, on el comportament de mercat difereix del període de validació.

4 Models

S'implementen 9 models que cobreixen totes les famílies tractades al curs: benchmarks, models estadístics, machine learning i deep learning.

Nota: el codi de cada model ha estat generat amb l'assistència d'un model d'intel·ligència artificial i pot contenir errors no detectats per l'estudiant. L'objectiu no és obtenir implementacions de producció, sinó tenir una comparativa orientativa que permeti identificar quina família de models té més potencial de millora en aquest context concret.

4.1 Benchmarks

Naïve. Prediu que el preu de demà serà igual al d'avui: $\hat{y}_{t+h} = y_t$. És el *benchmark* de referència per a cotitzacions de borsa. En un mercat eficient, és notòriament difícil de superar de manera consistent.

Drift. Extensió del Naïve amb una tendència lineal constant estimada sobre tota la finestra d'entrenament:

$$\hat{y}_{t+h} = y_t + h \cdot \frac{y_t - y_1}{t-1}$$

Pot funcionar bé si la sèrie té una tendència molt estable, però és sensible a punts de canvi.

4.2 Models estadístics

ETS / Holt. Suavitzat exponencial de doble nivell (Holt): modela nivell i tendència localment, ponderat exponencialment. Els intervals de predicció s'obtenen de la distribució gaussiana dels errors.

ARIMA. Model autoregessiu integrat de mitja mòbil. L'ordre (p, d, q) es selecciona automàticament via `pmdarima` (*auto-ARIMA*). En teoria, la primera diferència del preu és estacionària, cosa que fa ARIMA un candidat natural. En la pràctica, els preus absoluts no estacionaris limiten la seva eficàcia.

GARCH. Model d'heterocedasticitat condicional autoregressa generalitzada. Captura l'**agrupació de volatilitat** característica de les cotitzacions (períodes de calma alternats amb períodes turbolents). La predicció puntual és idèntica al Naïve; la millora rau en els intervals de confiança dinàmics.

4.3 Machine learning

Ambdós models de ML utilitzen lags del preu com a features: $\mathbf{x}_t = [y_t, y_{t-1}, \ldots, y_{t-L+1}]$ amb $L = 30$ dies.

Random Forest. Conjunt de $n = 300$ arbres de decisió entrenats per *bagging*. La predicció és la mitjana dels arbres; la incertesa s'estima a partir de la desviació estàndard dels residus en un conjunt *heldout*.

XGBoost. *Gradient boosting* amb construcció iterativa d'arbres. L'*early stopping* utilitza el mateix *heldout* intern per evitar sobreajust. Generalment més precís que RF en sèries amb tendències suaus.

4.4 Deep learning

Ambdues xarxes utilitzen una finestra de context de 30 dies, normalització z-score de l'entrada, i MC Dropout per quantificar la incertesa via mostreig Monte Carlo.

LSTM (Long Short-Term Memory). Xarxa recurrent amb tres portes (oblit, entrada, sortida) que permet capturar dependències a llarg termini. La seva major capacitat expressiva respecte a GRU comporta, en aquest context, un risc d'overfit mes elevat.

GRU (Gated Recurrent Unit). Versió alleugerida del LSTM amb dues portes (actualització i restabliment). Menys paràmetres, entrenam amb *early stopping*, el que el protegeix millor del sobreajust.

4.5 Models descartats

Model	Motiu del descart
SARIMA	Cap estacionalitat periòdica clara en cotitzacions diàries.
Filtre de Kalman	Complexitat elevada sense benefici clar per a sèries sense buits.
VAR / VECM	Requereix múltiples sèries endògenes; problema univariant.
Transformers	Overkill per a una sola sèrie; guany incert vs. GRU.
TCN / CNN temporal	Poc natural per a borsa; patrons locals no estables.

Taula 2: Models descartats i justificació.

5 Resultats

5.1 Ranking final

#	Model	MASE	MAE ($)	RMSE ($)	CV MAE ($\pm\sigma$)	Cob. 80 / 95%
1	**GRU**	**6.16**	**15.36**	**19.83**	13.14 ± 12.80	63.6% / 100%
2	XGBoost	11.15	27.81	31.74	33.79 ± 37.75	**81.8%** / 100%
3	RandomForest	11.47	28.59	31.26	25.50 ± 29.43	72.7% / 100%
4	Drift	13.73	34.23	40.88	8.33 ± 9.63	27.3% / 50.0%
5	ARIMA	14.31	35.67	42.59	13.37 ± 21.42	31.8% / 100%
6	Naïve	14.33	35.72	42.66	8.66 ± 9.38	31.8% / 45.5%
7	GARCH	14.33	35.72	42.66	8.66 ± 9.38	31.8% / 45.5%
8	ETS/Holt	14.34	35.75	42.69	8.64 ± 9.38	27.3% / 45.5%
9	LSTM	16.87	42.05	50.22	14.76 ± 13.52	45.5% / 50.0%

Taula 3: Ranking final ordenat per MASE. En verd: millor model. En groc: baseline.

6 Discussió

6.1 GRU — Model guanyador

El GRU és l'únic model que millora significativament el Naïve: el seu MASE de 6.16 representa una reducció del **57%** en l'error respecte al baseline (MASE = 14.33), i el seu MAE de $15.36 és pràcticament la meitat del Naïve ($35.72).

El seu avantatge prové de la combinació de diverses decisions de disseny. Treballar amb una finestra de 30 dies li permet detectar dependències que els models estadístics no poden capturar, sense la rigidesa d'un ordre fix com ARIMA. La normalització z-score estabilitza l'aprenentatge en una sèrie amb tendència creixent, i l'early stopping evita el sobreajust que precisament penalitza el LSTM. Finalment, el MC Dropout permet quantificar la incertesa de manera probabilística, obtenint una cobertura del 100% al 95% — encara que al 80% la cobertura cau al 63.6%, indicant intervals massa estrets: el mercat del test es va moure més del que el període de validació suggeria.

6.2 LSTM — Per què falla on GRU triomfa

El LSTM (MASE = 16.87) és pitjor fins i tot que el Naïve. La seva major complexitat (més paràmetres que GRU) no es tradueix en millor rendiment, sinó en sobreajust: el CV MAE ($14.76) és molt millor que el test MAE ($42.05), evidenciant un *gap* de generalització que l'early stopping no arriba a controlar.

6.3 Random Forest i XGBoost — Competitius però inestables

Amb MASE de 11.2–11.5, milloren el Naïve en un 20%. El seu punt feble és l'alta variabilitat entre folds: la desviació estàndard del CV MAE és de 29–38 dòlars, indicant que el rendiment depèn fortament del període de validació. Això limita la fiabilitat de la predicció en producció.

Calibració dels intervals. Com que ambdós models memoritzen el training set, calcular la incertesa sobre les mateixes dades d'entrenament produïa intervals col · lapsats (cobertura 0%). La solució va ser estimar-la sobre un *heldout set* reservat del 10% final del train, portant la cobertura fins al 72–82% (al 80%) i al 100% (al 95%).

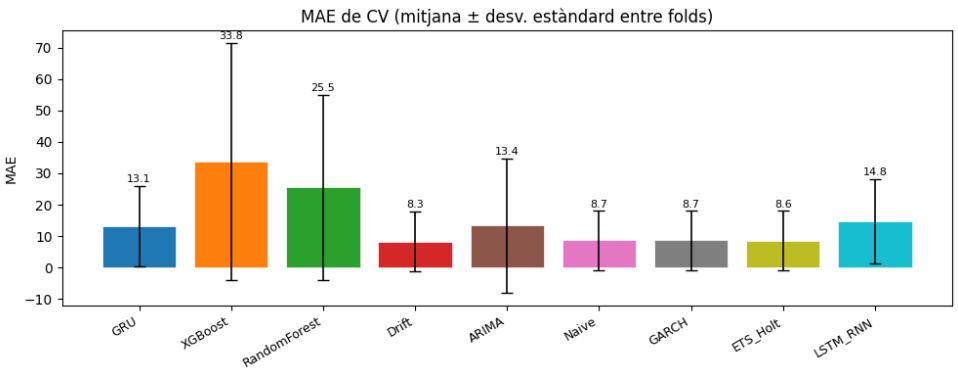

Figura 1: MAE mitjà ± desviació estàndard als 10 folds de CV. Les barres d'error llargues indiquen inestabilitat entre períodes.

6.4 Models estadístics — Limitació estructural

ARIMA, ETS, GARCH, Drift i Naïve obtenen MASE de 13.7–14.4, pràcticament idèntics entre si. El problema és comú a tots: estan dissenyats per a sèries que oscil · len al voltant d'un valor estable, i el preu de Microsoft no ho fa — ha passat de 42$ a 539$ en deu anys. Quan el preu arriba a rangs mai vistos durant l'entrenament, les prediccions queden molt desviades.

Els intervals de confiança pateixen el mateix problema: assumeixen que la variació típica del preu és sempre la mateixa, quan en realitat un moviment de 10$ és molt diferent quan el preu és 50$ que quan és 500$. Això explica les cobertures al 80% de tan sols el 27–32%, molt per sota del nominal. GARCH, tot i estar dissenyat específicament per modelar la volatilitat, no millora la predicció puntual perquè la seva estimació del preu de demà és idèntica a la del Naïve.

6.5 Calibració dels intervals al test set

La calibració conformal garanteix cobertura nominal en CV, però al test set apareix divergència per causa del canvi de distribució:

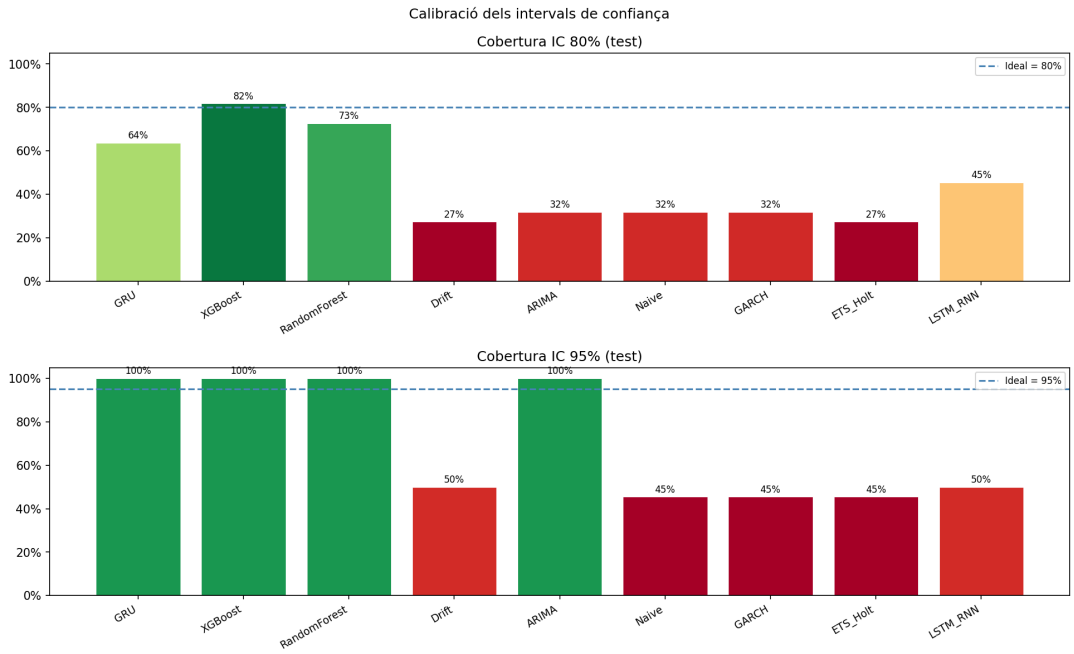

Figura 2: Cobertura real dels intervals de confiança al 80% i 95% en el test set. La línia blava indica el valor nominal ideal. Colors: verd = prop del nominal, vermell = lluny del nominal.

Els intervals resulten massa amples (cobertura superior a la promesa) per a ARIMA i GRU al nivell del 95%. En canvi, són massa estrets per a GRU al 80% i per a Drift, ETS, GARCH i Naïve a tots dos nivells. L'única calibració correcta al 80% l'obtenen XGBoost i RandomForest.

7 Conclusions

1. **GRU és el millor model**: MASE = 6.16, MAE = \$15.36, cobertura 100% @ 95%. És el únic dels 9 models que supera substancialment el Naïve en precisió puntual.

2. **La hipòtesi del mercat eficient es confirma parcialment**: cap model estadístic ni benchmark supera el Naïve, consistent amb la naturalesa de *random walk* dels preus absoluts.

3. **La calibració dels intervals de RF i XGBoost requeria residus out-of-sample**: un error trivial (residus in-sample en lloc d'out-of-sample) portava a una cobertura del 0%, invalidant completament els intervals de confiança d'ambdós models.

4. **Modelar preus absoluts penalitza tots els models estadístics**: la no-estacionarietat de la sèrie és el principal obstacle per a ARIMA, ETS i GARCH. La transformació a log-retorns és la millora més important per implementar en V3.

5. **La variabilitat entre folds de CV és un indicador clau**: models amb alta σ_{CV} (RF: 29\$, XGBoost: 38\$) són inestables en producció tot i tenir bon MAE mitjà.

7.1 Millores proposades

1. **Modelar log-retorns**: transformació $r_t = \ln(y_t/y_{t-1})$. Fa la sèrie estacionària, escala amb el nivell, i millora estructuralment ARIMA, ETS i GARCH. Requereix recompondre la predicció final via exponencial acumulada.

2. **LSTM**: reduir capacitat (menys capes, augmentar dropout, afegir *weight decay*) per controlar el sobreajust.

3. **RF / XGBoost**: substituir lags de preu absolut per features de log-retorn i volatilitat realitzada. Hauria de reduir la variabilitat entre folds.

4. **GRU**: explorar finestres de context més llargues (>30 dies) i arquitectures amb mecanisme d'atenció (*Temporal Fusion Transformer*).